



**UNIVERSITÉ
DE GENÈVE**

Université de Genève
Faculté des sciences
Maîtrise universitaire en sciences informatiques

Travail de master
Compatibilité de personnalité et
collaboration : une approche MBTI des
relations entre acteurs

Superviseur :
Prof. Roland BOUFFANAIS

Etudiant :
David Gabriel PAPA

Année Académique 2025-2026

Abstract

L'indicateur de personnalité de Myers-Briggs (MBTI) est largement utilisé pour décrire les modes d'interaction sociale des individus mais son influence réelle sur la structuration des réseaux sociaux reste débattue. Ce travail cherche s'il existe un lien entre le type de personnalité MBTI d'un acteur et leurs relations. À partir d'un réseau de co-casting construit sur la période 1990-2009, nous avons calculé un ensemble de métriques de centralité (degré, intermédiarité, proximité, PageRank, vecteur propre, coefficient de clustering, effet rich club) afin de caractériser la position structurelle des acteurs selon leur type MBTI. Une classification non supervisée par K-Means a ensuite été appliquée aux quatre dimensions continues du MBTI pour rechercher l'émergence éventuelle de communautés en termes de personnalité. Les résultats ne révèlent aucune structuration significative du réseau de collaboration par le type MBTI : les positions centrales et les communautés détectées rassemblent des profils de personnalité hétérogènes, sans tendance marquée à l'homophilie ni à l'hétérophilie. Ces résultats suggèrent que la personnalité MBTI ne constitue pas un facteur déterminant de l'organisation des réseaux de collaboration professionnelle à grande échelle, contrairement à ce qui est parfois observé dans des contextes d'équipes restreintes et structurées.

Mots-clés : données, MBTI, réseaux, lien, collaboration, homophilie, hétérophilie, centralité, K-Means, classification, acteur, film, personnalité,

Table des matières

1	Introduction	4
1.1	MBTI	4
1.2	But/Motivations	4
1.3	État de l'art	4
2	Méthodologie	7
2.1	Structure et environnement de travail	7
2.1.1	Traitement des données des acteurs/films	7
2.1.2	Traitement des données MBTI	7
2.1.3	Construction et analyse de notre réseau	8
2.2	Données acteurs	8
2.3	Données MBTI	9
2.3.1	Toute la base de données	9
2.3.2	Tous les acteurs dans la base de données	11
2.4	Construction du réseau	14
2.4.1	Centralité des acteurs	15
2.4.2	Phénomène petit monde	16
2.4.3	Duo d'acteurs fréquents	17
2.4.4	Évolution du réseau au fil du temps	17
2.5	Réseau final	19
2.5.1	Correction d'erreurs	19
2.5.2	Jointure réseau et MBTI	19
2.5.3	Distribution du réseau	20
2.6	Évaluation	23
2.6.1	Calcul de l'indépendance	23
2.6.2	Homophilie	24
2.6.3	Hétérophilie	30
3	Resultats	35
3.1	Homophilie	35
3.1.1	Réseau complet	35
3.1.2	Réseau sans inconnu	43
3.2	Hétérophilie	50
3.2.1	Distribution par film	50
3.2.2	Score d'hétérophilie	51
3.2.3	Formation de communautés	53
4	Discussion et travail futur	56
5	Conclusion	57
	Références	58

1 Introduction

1.1 MBTI

Le MBTI, acronyme de Myers-Briggs Type Indicator, est un outil d'évaluation de la personnalité développé au XX^e siècle. Il vise à mieux comprendre les différences individuelles en classant les préférences psychologiques des personnes selon quatre grandes dimensions :

- extraversion (E) / introversion (I)
- sensation (S) / intuition (N)
- pensée (T) / sentiment (F)
- jugement (J) / perception (P)

Le fonctionnement du MBTI repose sur la manière dont chacun perçoit le monde et prend des décisions. Il identifie un type de personnalité parmi seize combinaisons possibles. Cette évaluation ne mesure pas des compétences ni des capacités, mais plutôt des préférences naturelles dans la façon de fonctionner au quotidien. Utilisé dans des contextes variés comme le développement personnel, l'orientation professionnelle ou le travail en équipe, il représente avant tout un cadre de lecture des comportements humains.

1.2 But/Motivations

Dans la continuité de cette analyse de personnalité, nous allons chercher à trouver l'existence éventuelle d'un lien entre la personnalité des individus et celle des personnes qu'ils fréquentent. L'objectif est de comprendre si nos relations sociales reflètent, au moins en partie, notre propre manière de penser, de ressentir et d'agir, ou si au contraire elles reposent davantage sur des complémentarités de profils.

Pour cela, nous nous pencherons sur un réseau d'acteurs afin d'observer d'éventuelles tendances dans les relations interpersonnelles. Il s'agira d'examiner si certaines personnalités ont tendance à se rapprocher de profils similaires partageant des caractéristiques communes ou si elles sont davantage attirées par des individus aux fonctionnements opposés. Cette démarche permettra ainsi d'explorer la manière dont les préférences psychologiques peuvent influencer les choix relationnels et la construction des cercles sociaux.

1.3 État de l'art

Les relations sociales ont longtemps été étudiées à travers le concept d'homophilie, défini par Lazarsfeld et Merton [7] comme la tendance des individus à établir des liens avec des personnes qui leur ressemblent. À l'inverse, l'hétérophilie désigne l'attraction entre individus présentant des caractéristiques différentes, mettant en avant une logique de complémentarité plutôt que de ressemblance. Ce couple conceptuel a été appliqué à de nombreux marqueurs identitaires [8] avant d'être étendu aux traits de personnalité. Dans le champ de la psychologie et des sciences des réseaux [2, 3, 11, 5, 10, 4], plusieurs travaux se sont penchés sur le lien entre personnalité et structuration des relations sociales, avec des résultats contrastés selon le contexte étudié.

Plusieurs études menées dans des contextes organisationnels ou pédagogiques mettent en évidence des tendances homophiliques. Dans le domaine du développement logiciel, Gilal et al. [6] ont appliqué une approche de réseaux complexes à des données MBTI d'étudiants en génie logiciel, afin d'identifier les profils de personnalité les plus "centraux" dans les choix de coéquipiers. Leurs résultats montrent que certains types comme INTJ et ESTP sont les plus fréquemment choisis comme partenaires, tandis qu'ENTJ et INTP se distinguent par leur forte centralité de proximité, suggérant une capacité à travailler proche des autres profils. À l'inverse, des types comme INFP, ISFP, INFJ et ISTJ apparaissent peu connectés dans le réseau, ce qui contredit

en partie la littérature antérieure attribuant à ISTJ le profil de programmeur par excellence, illustrant la complexité et parfois l'incohérence des résultats selon l'angle de mesure choisi.

D'autres recherches mettent en évidence l'importance de la complémentarité plutôt que de la similarité, en particulier dans des contextes où les rôles sont différenciés, comme le travail en équipe logicielle. Garousi et Tarhan [4] ont mené une étude de cas exploratoire auprès de 50 étudiants en génie logiciel, répartis en groupes homogènes ou mixtes selon la dimension Introversion/Extraversion du MBTI. Leurs résultats montrent que la composition par personnalité n'a pas d'effet significatif sur la cohésion d'équipe mais que les groupes mixtes obtiennent en moyenne de meilleures notes de projet, en particulier pour les étudiants ayant une moyenne académique plus faible, suggérant que la diversité de personnalité peut compenser des écarts de compétence technique sans nuire à la cohésion sociale. Ce contraste souligne que l'effet de l'homogénéité ou de l'hétérogénéité de personnalité dépend fortement du type de tâche accompli par le groupe.

Une autre branche de la littérature, plutôt que de s'intéresser aux liens entre individus, cherche à établir des correspondances entre types de personnalité et aptitude à des rôles spécifiques du cycle de vie logiciel. Capretz et Ahmed [3] ont proposé une cartographie des quatre dimensions du MBTI vers les cinq grandes phases du développement logiciel (analyse, conception, programmation, test, maintenance) en s'appuyant sur l'analyse d'offres d'emploi et de compétences attendues. Ils concluent par exemple que les profils EF sont préférables pour l'analyse système, NT pour la conception, IST pour la programmation, SJ pour le test et SP pour la maintenance.

Varona et Capretz [10] ont approfondi cette approche en formalisant un "coefficient de disposition naturelle", calculé comme le ratio entre le nombre de règles satisfaites par un type MBTI donné et le nombre total de règles identifiées pour un rôle, à partir des préférences déclarées par des praticiens logiciels pour certaines tâches. Cette modélisation produit une matrice de décision qui peut appuyer l'affectation des ressources humaines dans les projets logiciels, mais repose sur l'hypothèse implicite que certains types sont intrinsèquement mieux disposés pour certains rôles.

Thatcher et De la Cour [9] ont examiné si l'effet de la personnalité (MBTI) sur les processus de prise de décision en petit groupe variait selon le moyen de communication en face-à-face ou médiatisés par ordinateur. Contrairement à l'hypothèse dominante dans la littérature, l'extraversion (pourtant identifiée comme le facteur le plus fréquemment invoqué pour expliquer les différences de participation) ne montre aucun effet significatif, ni en face-à-face ni en médiation informatique. Seule la dimension T/F (Thinking/Feeling) ressort de façon robuste, les profils "Feeling" obtenant des scores plus élevés de leadership, d'initiative et de sensibilité interpersonnelle, indépendamment du média. Ce résultat invite à la prudence quant à la place centrale souvent accordée à l'extraversion dans l'étude des interactions sociales fondées sur la personnalité.

La question de la persistance de l'homophilie de personnalité lorsque les marqueurs identitaires habituels sont supprimés constitue un axe de recherche plus récent, directement pertinent pour l'étude de larges réseaux d'acteurs. Ayyoubzadeh et al. [1] ont mené une analyse de réseau complexe sur plus de 288000 messages échangés entre 6076 utilisateurs d'un système de chat anonyme, dont 940 ont volontairement renseigné leur type MBTI et leur genre. Leurs résultats indiquent une nette dominance des interactions hétérophiles (89,3% des interactions), en particulier entre types cognitivement complémentaires (NT et NF), tandis que l'homophilie de personnalité ne représente que 10,7% des interactions, concentrée principalement chez les types intuitifs-introvertis (INTJ, INFP, INFJ). Le réseau présente des propriétés de réseau invariant d'échelle avec des noeuds-hubs à haute centralité assurant la cohésion entre communautés, et une modularité relativement faible indiquant que la personnalité ne structure que faiblement la formation des communautés. Fait notable, le genre apparaît comme un facteur d'homophilie bien plus robuste que le type MBTI : les utilisatrices présentent un taux d'homophilie de genre de 55,6% contre 23,4% pour les utilisateurs masculins, suggérant que l'anonymat ne supprime pas uniformément tous les marqueurs de regroupement social.

Ce résultat s'inscrit dans un débat théorique plus large entre deux hypothèses concurrentes : l'hypothèse de persistance de l'homophilie (les signaux de personnalité subsisteraient même sous anonymat) et l'hypothèse d'amplification de l'hétérophilie (l'anonymat réduirait les contraintes sociales habituelles et favoriserait l'exploration de profils différents). Les travaux cités par cette étude vont également dans le sens d'un affaiblissement de l'homophilie de personnalité en contexte anonyme, au profit d'autres formes de similarité.

Ainsi, bien que l'influence de la personnalité sur les relations sociales soit largement reconnue, la question de savoir si les individus privilégient la similarité ou la complémentarité demeure ouverte et dépend fortement :

- du type de tâche accomplie par le groupe,
- du degré de structuration du contexte (équipe projet avec rôles définis vs. interaction libre)
- et du degré d'anonymat de l'environnement étudié.

Il est important de noter que de nombreuses études dans ce domaine ont été réalisées sur des populations spécifiques, notamment des groupes d'étudiants ou des équipes professionnelles de taille restreinte. Ces contextes présentent l'avantage d'être facilement accessibles pour la collecte de données et de permettre un contrôle expérimental fin, mais ils limitent la généralisation des résultats à des populations plus larges et plus diverses. Par ailleurs, plusieurs recherches se concentrent sur des environnements structurés [9, 4, 6, 11] (équipes de travail, groupes projet), où les relations sont contraintes par des objectifs communs et des rôles prédéfinis, ce qui peut artificiellement renforcer ou masquer des effets de personnalité qui se manifesteraient différemment dans un cadre social plus libre. Cette problématique justifie l'intérêt de poursuivre les investigations, notamment à travers l'analyse de réseaux d'acteurs à grande échelle dont de larges volumes de données sont disponibles, afin de mieux comprendre les mécanismes spontanés qui incite à la formation de liens interpersonnels en fonction des traits de personnalité.

2 Méthodologie

2.1 Structure et environnement de travail

Ce travail peut être divisé en 3 parties :

- Traitement des données des acteurs/films
- Traitement des données MBTI
- Construction et analyse de notre réseau

Le travail étant réalisé avec Python 3.13, nous avons utilisé des notebooks qui donnent un visuel plus agréable et une meilleure structure pour notre travail et nos résultats. Nos trois notebooks correspondant à nos trois parties de travail sont présents sur le dépôt Git : <https://github.com/DavidGabrielPapa/TheseDeMaster>

2.1.1 Traitement des données des acteurs/films

Le travail sur cette partie se trouve dans le notebook : `dataset.ipynb`.

Plusieurs librairies Python ont été utilisées pour différentes étapes :

Lirairies	Utilisations
kagglehub, os	Lecture de la base de données en ligne et son importation
pandas	Manipulation et visualisation de la base de données
matplotlib.pyplot	Visuel pour les graphiques
json	Lecture des fichiers <code>.json</code> contenant le casting des films
networkx	Création de notre réseau et analyse de certaines caractéristiques

TABLE 1 – Liste des librairies Python et leurs utilisations

2.1.2 Traitement des données MBTI

Le travail sur cette partie se trouve dans le notebook : `mbti.ipynb`.

Comme précédemment, plusieurs librairies Python ont été utilisées pour différentes étapes. Les librairies listées précédemment ont été utilisé de la même manière dans ce notebook mais nous ne les avons pas relisté ici :

Lirairies	Utilisations
difflib	Utilise la méthode <code>get_close_matches()</code> pour faire correspondre 2 noms
scipy.stats	Utilise la méthode <code>chi2_contingency()</code> pour calculer le χ^2
numpy	Permet de faire des calculs mathématiques
seaborn	Utilisé pour créer des cartes de chaleur
unicodedata, re	Sert à modifier du texte, le nettoyer
collections	Utilisé dans Fuzzy-names

TABLE 2 – Liste des librairies Python et leurs utilisations

2.1.3 Construction et analyse de notre réseau

Le travail sur cette partie se trouve dans le notebook : `graph.ipynb`.

Les librairies listées précédemment ont été utilisées de la même manière dans ce notebook mais nous listons ici uniquement celles nouvellement utilisées :

Librairies	Utilisations
<code>sklearn.cluster</code>	Permet de calculer le K-means et le DBSCAN
<code>sklearn.preprocessing</code>	Permet de centrer et réduire des données
<code>sklearn.metrics.pairwise</code>	Permet d'utiliser la méthode <i>euclidean_distances</i>
<code>itertools</code>	Génère nos combinaisons à partir de la liste des dimensions
<code>community</code>	Permet de calculer les communautés avec Louvain
<code>kneed</code>	Permet de calculer le coude de k-means

TABLE 3 – Liste des librairies Python et leurs utilisations

2.2 Données acteurs

Dans un premier temps, nous allons utiliser une base de données (DB) de films contenant aussi le casting de leurs acteurs. Ces données proviennent de [Kaggle](#). Toutes les manipulations et informations récupérées dans cette base de données seront effectuées dans le fichier `dataset.ipynb`.

Afin d'avoir un meilleur aperçu de notre base de données, nous analysons d'abord la distribution des films par décennie pour avoir une idée des films à disposition.




FIGURE 1 – Films par décennie

Nous remarquons que notre DB contient surtout des films récents (après 1990), nous disposons donc de 2826 films pour faire notre recherche sur des films entre 1990 et 2009. Comme nous travaillerons avec les acteurs, nous pouvons compter le nombre d'acteurs contenu dans cette DB et comparer avec ceux sur la période souhaitée :

Description	Nombre	Ratio (%)
Number of unique actors (all database)	54 201	100%
Number of unique actors between 1990 and 2009	30 748	56.73%

TABLE 4 – Nombre d'acteurs

Les acteurs étant enregistrés sous format `.json` dans notre DB, nous utilisons la librairie `json` de Python afin d'y avoir accès facilement. A l'aide de la fonction `get_top_actors(cast_json,`

nbr), nous définissons le nombre (nbr) d'acteur à extraire par film, selon leur ordre d'importance (si nbr=1, on prend juste l'acteur principal). Si le nombre d'acteurs souhaités dépasse le nombre d'acteurs contenus, nous renvoyons simplement le nombre maximum d'acteurs contenus. Ceci nous servira pour la [construction de notre réseau](#).

2.3 Données MBTI

Les informations sur la personnalité que nous utiliserons proviennent aussi d'une base [Kaggle](#) contenant une liste de personnalités célèbres dans le monde.

La base de données étant très complète et contenant beaucoup d'informations inutiles pour notre travail, nous la réduirons en ne gardant que les colonnes pertinentes.

```
# Columns to keep
cols = ['name', 'category', 'subcategory', 'four_letter', 'letter_1',
        'letter_1_percentage', 'letter_2', 'letter_2_percentage', 'letter_3',
        'letter_3_percentage', 'letter_4', 'letter_4_percentage']

mbti = mbti[cols]
```

Ensuite, nous supprimons les lignes identiques afin d'éviter des erreurs.

Description	Nombre de lignes
Before cleaning	50 878
After cleaning	50 791

TABLE 5 – Nombres de lignes dans la DB MBTI

Nous analysons notre base de données en la séparant de trois façons différentes.

2.3.1 Toute la base de données

Pour repérer une potentielle tendance à prendre en compte plus tard dans notre étude, nous pouvons visualiser la distribution des profils de personnalité au sein de notre DB.




FIGURE 2 – Distribution des types MBTI (all DB)

Type MBTI	Effectif	Pourcentage
ENFP	5 465	10.8%
ENTP	4 659	9.2%
INFP	3 776	7.4%
ESFP	3 619	7.1%
INFJ	3 578	7.0%
ISFP	3 392	6.7%
INTP	3 371	6.6%
ENFJ	3 247	6.4%
ESTP	2 847	5.6%
INTJ	2 732	5.4%
ESFJ	2 643	5.2%
ISTP	2 508	4.9%
ENTJ	2 402	4.7%
ISTJ	2 255	4.4%
ISFJ	2 243	4.4%
ESTJ	2 054	4.0%

TABLE 6 – Distribution des types MBTI (toute la DB)

Après une vue globale, nous observons une répartition décroissante mais aucune tendance claire. Nous nous penchons sur la distribution par lettres afin d'être plus précis sur les informations de personnalité :




FIGURE 3 – Distribution des lettres par position (toute la DB)

Position	Lettre A	Lettre B	Répartition
1ère lettre	E : 26 936	I : 23 855	53.0% - 47.0%
2ème lettre	N : 29 230	S : 21 561	57.5% - 42.5%
3ème lettre	F : 27 963	T : 22 828	55.1% - 44.9%
4ème lettre	P : 29 637	J : 21 154	58.4% - 41.6%

TABLE 7 – Distribution des lettres par position (toute la DB)

Afin de s'assurer que chacune de nos dimensions sont indépendantes, nous regardons leur matrice de corrélation.




FIGURE 4 – Matrice de corrélation (all DB)

Les valeurs étant proche de 0, avec cette matrice nous ne pouvons pas noter de lien entre les dimensions. Pour s'en assurer, nous calculons le **p-value** qui sert à tester si deux variables sont indépendantes. Afin d'appuyer notre mesure de **p-value**, nous calculons le **V de Cramér** qui mesure la force de l'association entre deux variables catégorielles.

Test χ^2	p-value	V de Cramér
letter_1 - letter_2	0.0000	0.0216
letter_1 - letter_3	0.0101	0.0114
letter_1 - letter_4	0.0000	0.0698
letter_2 - letter_3	0.6378	0.0021
letter_2 - letter_4	0.0001	0.0173
letter_3 - letter_4	0.2457	0.0052

TABLE 8 – Tests du p-value et V de Cramér (toute la DB)

Bien que certaines **p-value** soient proches de 0 dans notre tableau, tous nos **V de Cramér** sont inférieurs à 0.1 et donc n'indiquent aucun lien entre nos dimensions.

2.3.2 Tous les acteurs dans la base de données

Afin d'être plus précis, nous nous penchons sur les personnes enregistrées comme "acteur" dans notre base de données grâce à la section "subcategory" :

Description	Nombre
Toute la base de données	50 791
Tous les "acteurs" de la DB	6 914

TABLE 9 – Nombres d'acteurs dans la DB MBTI

Nous constatons une nette diminution de la quantité de données. Pour nous assurer d'avoir des résultats pertinents et cohérents, nous allons vérifier la distribution selon le profil MBTI de manière similaire à celle précédente :




FIGURE 5 – Distribution des types MBTI (pour les acteurs)

Type MBTI	Effectif	Pourcentage
ENFP	1 016	14.7%
ENFJ	645	9.3%
INFJ	581	8.4%
INFP	565	8.2%
ISFP	551	8.0%
ENTP	537	7.8%
ESFJ	524	7.6%
ESFP	517	7.5%
ISFJ	366	5.3%
ESTP	355	5.1%
ISTP	306	4.4%
INTP	243	3.5%
ENTJ	195	2.8%
INTJ	180	2.6%
ISTJ	180	2.6%
ESTJ	153	2.2%

TABLE 10 – Distribution des types MBTI (pour les acteurs)




FIGURE 6 – Distribution des lettres par position (pour les acteurs)

Position	Lettre A	Lettre B	Répartition
1ère lettre	E : 3 942	I : 2 972	57.0% - 43.0%
2ème lettre	N : 3 962	S : 2 952	57.3% - 42.7%
3ème lettre	F : 4 765	T : 2 149	68.9% - 31.1%
4ème lettre	P : 4 090	J : 2 824	59.2% - 40.8%

TABLE 11 – Distribution des lettres par position (pour les acteurs)

Par rapport à la partie précédente, nous remarquons une dominance de la lettre F en 3ème position, ce qui indique qu'en moyenne, les acteurs sont plus sentimentaux (Feeling) que la répartition globale. Pour les autres lettres, nous notons un plus grand écart que précédemment mais pas assez grand pour être significatif directement. Nous vérifions la corrélation entre les lettres étant donnée que notre distribution est différente afin de s'assurer de indépendance de nos paramètres :




FIGURE 7 – Matrice de corrélation (pour les acteurs)

Nous y remarquons une légère tendance entre la 3ème et 4ème lettre. Nous calculons le [p-value](#) ainsi que le [V de Cramér](#) afin de voir si cette corrélation est significative :

Test χ^2	p-value	V de Cramér
letter_1 - letter_2	0.0000	0.0789
letter_1 - letter_3	0.4544	0.0090
letter_1 - letter_4	0.0000	0.0550
letter_2 - letter_3	0.0001	0.0480
letter_2 - letter_4	0.4069	0.0100
letter_3 - letter_4	0.0000	0.1076

TABLE 12 – Tests du p-value et V de Cramér (pour les acteurs)

Contrairement à la partie avec toute notre base de données, nous avons un **V de Cramér** plus important et significatif entre la lettre 3 et 4 ce qui appuie le résultat de notre matrice de corrélation. Afin de voir si ces deux paramètres ne sont pas trop dépendants, nous contrôlons leur probabilité conditionnelle :




FIGURE 8 – Probabilité conditionnelle lettre 3 et 4 (pour les acteurs)

La distribution conditionnelle entre les dimensions T/F et J/P met en évidence une prédominance du profil P dans les deux groupes. Toutefois, cette tendance est plus marquée chez les individus de type T (67%) que chez les individus de type F (56%). Bien que le **test du χ^2** indique une dépendance statistique entre ces variables, le **V de Cramér** reste faible bien que plus important que précédemment, suggérant une association limitée.

2.4 Construction du réseau

Pour construire notre réseau, nous itérons sur nos films contenus dans notre intervalle d'années souhaitées pour y extraire un nombre d'acteurs choisis par film (même nombre d'acteurs pour tous les films). Avec notre liste d'acteurs ainsi obtenue, nous créons un graph avec un lien entre chaque acteur ayant joué dans un même film. Comme notre graphe n'est pas pondéré, si un lien se répète dans un autre film il est simplement ignoré. Nous pouvons ainsi varier le nombre d'acteurs à extraire afin de voir l'évolution entre le nombre total d'acteurs extraits et le nombre de lien entre eux.




FIGURE 9 – Comparaison du nombre d'acteurs et de liens en fonction du nombre d'acteurs extrait par film

Nous pouvons constater une croissance linéaire du nombre d'acteurs uniques contrairement au nombre de liens qui croît de manière supralinéaire.




FIGURE 10 – Illustration du réseau construit (simplifié en gardant que les noeuds de degré ≥ 20)

2.4.1 Centralité des acteurs

Pour avoir une idée de l'évolution de notre réseau, nous vérifions la centralité des acteurs en fonction du nombre d'acteurs extraits. Ici, nous montrons la moyenne de co-acteurs (degré moyen) mais dans le code contenu dans le fichier `dataset.ipynb` il est aussi possible de voir le top 3 betweenness et PageRank.

Nombre d'acteurs extraits	Nombre d'acteurs uniques	Nombre de liens	Moyenne de co-acteurs
3	3 455	8 119	4.7
4	4 569	16 184	7.1
5	5 732	26 811	9.4
6	6 894	39 772	11.5
7	8 086	54 894	13.6
8	9 281	72 063	15.5
9	10 486	90 936	17.3
10	11 637	111 299	19.1

TABLE 13 – Évolution du degré moyen du réseau en fonction du nombre d'acteurs extraits

2.4.2 Phénomène petit monde

Nous nous penchons ensuite sur le plus court chemin entre acteurs et si un phénomène de petit monde est observable :

Nombre d'acteurs extraits	Distance moyenne minimum	Clustering coefficient
3	4.62	0.6207
4	4.24	0.6731
5	4.01	0.6993
6	3.85	0.7173
7	3.77	0.7338
8	3.70	0.7450
9	3.61	0.7545
10	3.55	0.7610

TABLE 14 – Évolution des propriétés de petit monde en fonction du nombre d'acteurs extraits

Un réseau présente les propriétés du petit monde si la distance moyenne entre les noeuds est faible et si le coefficient de clustering est élevé. Avec un clustering à plus de 60% et une distance moyenne inférieure à 5, nous avons déjà un phénomène de petit monde dans les conditions initiales. En augmentant notre nombre d'acteurs extrait, nous amplifions ce phénomène.




FIGURE 11 – Évolution des phénomènes de petit monde (distance et clustering)

2.4.3 Duo d'acteurs fréquents

Nous inspectons si certains acteurs ont tendance à souvent jouer ensemble. Contrairement aux analyses précédentes, pour cette partie, nous devons refaire notre graphe mais de manière pondérée afin de compter le nombre de films en commun.

Nous remarquons que les binômes présents sont ceux provenant de saga comptant de nombreux films : Harry Potter, Star Trek, X-Men. Bien qu'intéressantes, ces informations ne nous sont pas utiles pour la suite de notre travail et ne seront donc pas développées.

2.4.4 Évolution du réseau au fil du temps

Nous travaillerons sur des films entre les années 1990 et 2009, cependant, il peut être intéressant de voir quelques informations globales selon les années.

Décennie	Nb acteurs	Nb liens	Densité	Composante principale
1960	182	213	0.0129	17
1970	264	325	0.0094	56
1980	633	807	0.0040	228
1990	1238	2294	0.0030	939
2000	2835	5889	0.0015	1962
2010	2389	4139	0.0015	1425

TABLE 15 – Évolution du réseau par décennie

Le nombre d'acteurs représente le nombre de noeuds du réseau, c'est-à-dire le nombre d'acteurs ayant joué dans au moins un film durant cette décennie et le nombre de liens représente le nombre de paires d'acteurs ayant collaboré dans un même film.

Nous voyons une forte croissance du nombre d'acteurs et de liens au cours des décennies qui

reflète l'expansion de notre base de données et du cinéma.




FIGURE 12 – Évolution du réseau d'acteurs au court des décennies

La densité est la proportion de liens existants par rapport au nombre de liens possibles. Un réseau de N acteurs peut théoriquement avoir $\frac{N(N-1)}{2}$ liens. Elle mesure à quel point le réseau est effectivement connecté (1 = tout le monde joue avec tout le monde).

Paradoxalement, plus le réseau grandit, plus il se dilue. Ce résultat semble logique étant donné que quand le nombre d'acteurs augmente, le nombre de collaborations possibles croît bien plus vite que les collaborations réelles.




FIGURE 13 – Évolution de la densité au court des décennies

En 1960, seulement 17 acteurs sur 182 ($\approx 9.3\%$) forment le cœur connecté du réseau. En 2000, ce sont 1962 sur 2835 ($\approx 69.2\%$). Le réseau passe d'un ensemble de petits groupes isolés à une grande structure fortement interconnectée, typique de l'émergence d'un réseau de **petit monde**.




FIGURE 14 – Évolution des structures connectées au court des décennies

2.5 Réseau final

Afin de maximiser notre nombre de correspondance avec notre base de données MBTI et d'obtenir de meilleurs résultats dans nos analyses, nous utiliserons notre réseau avec 10 acteurs extraits.

2.5.1 Correction d'erreurs

Lors de notre analyse du réseau, nous remarquons des incohérences qui se présentent sous forme de "selfloop" (un noeud qui pointe vers lui même). Il en existe 9 dans notre réseau pour les acteurs suivants :

- James Caan
- Corey Burton
- David Lascher
- Leo Rossi
- Chad Donella
- Richard Linklater
- Don Austen
- Nick Jameson
- Angelina Idnani

En regardant plus en détails comment cela a pu se produire, nous remarquons deux cas de figures : soit une erreur d'entrée dans la base de données est visible car l'acteur joue le même personnage et seul son "id" d'acteur change, soit un acteur joue plusieurs rôles dans un même film. Dans les deux cas un lien vers lui-même est créé à la [construction du réseau](#). Nous supprimons donc ces liens afin qu'ils n'influencent pas nos résultats étant donné que ce problème reste mineur.

2.5.2 Jointure réseau et MBTI

Nous commençons par regarder le nombre de personnes dans notre réseau d'acteurs et la longueur de notre base de données MBTI :

Catégorie	Nombre
Nombre d'acteurs dans le réseau	11 637
Nombre de célébrités dans MBTI	50 640

TABLE 16 – Statistiques sur le réseau et la base MBTI

En regardant simplement les noms, nous pouvons faire correspondre 2401 personnes de notre

réseau (20.6%). Parmi ces 2401 personnes, seulement 1912 sont défini comme acteurs dans notre base de données MBTI, cela s'explique car plusieurs acteurs proviennent initialement d'autres milieux, dont le principal est : Humoriste.

Pour essayer d'augmenter le nombre de personnes dont nous connaissons la personnalité dans notre réseau, nous utilisons la librairie `difflib` avec la méthode : `get_close_matches`. Avec une ressemblance fixée à 90% avant de vérifier nos résultats. Lorsqu'une normalisation est appliquée sur les noms avant d'effectuer une correspondance, les résultats ne sont pas plus pertinent, nous avons donc continué sans effectuer de normalisation au préalable. Nous obtenons ainsi 223 correspondances, cependant, en se penchant sur la liste de noms, nous remarquons que nous avons parfois une écriture différente pour une même personne et parfois simplement deux personnes différentes.

Nous effectuons une normalisation manuelle sur cette liste restreinte afin que les correspondances après ce filtre soient correctes et que nous n'ayons pas deux personnes différentes associées par erreur, quitte à omettre certaines correspondances correctes. Pour cela, nous commençons par supprimer les différents points et apostrophe qui peuvent varier selon les langues. Ensuite, nous enlevons tous les accents avant de mettre le tout en minuscule et de supprimer les espaces multiples (garder juste les espaces simples). Avec cette méthode, nous parvenons à faire correspondre 45 acteurs supplémentaires avec notre réseau pour atteindre la répartition suivante :

Catégorie	Nombre
Nombre d'acteurs dans le réseau	11 637
Nombre de célébrités dans MBTI	50 640
Nombre de correspondances	2 446

TABLE 17 – Correspondance entre les bases de données

Fuzzy-names

Pour faire correspondre les noms entre les deux bases de données, il existait déjà des manières de filtrer les correspondances. Comme il est impossible d'inclure une LLM (Large Language Model) directement dans le code gratuitement, nous avons testé le dépôt [Github](#) *fuzzy-names* qui permet de faire correspondre des noms. Le code étant en Swift, nous l'avons adapté à Python avec une LLM.

Le code fonctionne bien plus rapidement et obtient certaines correspondances pertinentes, cependant, certaines correspondances restent entre des personnes différentes. En y ajoutant un filtre afin de garder uniquement des réponses correctes, nous obtenons un nombre de correspondance de 42 qui est inférieur à notre procédé manuel. Nous utiliserons la correspondance manuelle pour la suite du travail mais le code reste présent dans le notebook `mbti.ipynb`.

2.5.3 Distribution du réseau

Maintenant que nous possédons notre liste de personnalité présente dans notre réseau, nous pouvons regarder notre distribution MBTI et comparer avec les distributions précédentes.




FIGURE 15 – Distribution des types MBTI (correspondance réseau)

Type MBTI	Effectif	Pourcentage
ENFP	321	13.3%
ENTP	226	9.4%
ENFJ	201	8.3%
ESFJ	187	7.7%
INFJ	179	7.4%
INFP	175	7.2%
ISFP	147	6.1%
ESTP	146	6.0%
ESFP	134	5.5%
ISTP	131	5.4%
INTP	127	5.3%
ISFJ	108	4.5%
ENTJ	96	4.0%
ISTJ	94	3.9%
INTJ	81	3.4%
ESTJ	63	2.6%

TABLE 18 – Distribution des types MBTI (correspondance réseau)




FIGURE 16 – Distribution des lettres par position (correspondance réseau)

Position	Lettre A	Lettre B	Répartition
1ère lettre	E : 1 374	I : 1 042	56.9% - 43.1%
2ème lettre	N : 1 406	S : 1 010	58.2% - 41.8%
3ème lettre	F : 1 452	T : 964	60.1% - 39.9%
4ème lettre	P : 1 407	J : 1 009	58.2% - 41.8%

TABLE 19 – Distribution des lettres par position (correspondance réseau)

Comme pour la distribution des [acteurs](#), nous avons une dominance de la lettre F. Notre réseau de correspondance reflète donc bien la tendance des acteurs observés précédemment. Nous effectuons les mêmes analyses de corrélations afin de s'assurer qu'avec notre réseau, aucune dépendance ne s'est installée.




FIGURE 17 – Matrice de corrélation (correspondance réseau)

Nous remarquons aussi une valeur légèrement plus significative entre les lettres 3 et 4. Nous procédons donc au calcul du [p-value](#) et du [V de Cramér](#).

Test χ^2	p-value	V de Cramér
letter_1 - letter_2	0.0003	0.0744
letter_1 - letter_3	0.1604	0.0286
letter_1 - letter_4	0.0283	0.0446
letter_2 - letter_3	0.0102	0.0523
letter_2 - letter_4	0.0130	0.0505
letter_3 - letter_4	0.0000	0.1167

TABLE 20 – Tests du p-value et V de Cramér (correspondance réseau)

Toujours dans la continuité de la ressemblance avec la base d'acteurs, nous avons un **V de Cramér** légèrement plus significatif entre les lettres 3 et 4. Nous allons observer leur probabilité conditionnelle afin de repérer un potentiel lien :




FIGURE 18 – Probabilité conditionnelle lettre 3 et 4 (correspondance réseau)

Même si le test du χ^2 indique une dépendance statistique entre ces variables, le **V de Cramér** reste faible, bien que plus important que précédemment, suggérant une association limitée. On ne peut pas indiquer une dépendance comme conclu dans l'analyse de la **base de données d'acteurs**.

2.6 Évaluation

2.6.1 Calcul de l'indépendance

Test du χ^2

Le test du χ^2 d'indépendance est une méthode statistique utilisée pour déterminer s'il existe une relation entre deux dimensions. Son objectif est de vérifier si les modalités d'une variable sont liées aux modalités de l'autre variable, ou si elles sont indépendantes.

On commence par formuler deux hypothèses :

- Hypothèse nulle (H_0) : les deux variables sont indépendantes, c'est-à-dire qu'il n'existe aucune relation entre elles.
- Hypothèse alternative (H_1) : les deux variables ne sont pas indépendantes.

On dispose d'un échantillonnage de N données. Notons O_{ij} l'effectif observé de données pour lesquelles X prend la valeur i et Y la valeur j . Sous l'hypothèse d'indépendance, nous nous attendons à une valeur espérée E_{ij} définie comme suit :

$$E_{ij} = \frac{O_{i+} \times O_{+j}}{N}$$

Où :

$$O_{i+} = \sum_{j=1}^J O_{ij}$$

(nombre de données pour lesquelles $X = i$)

$$O_{+j} = \sum_{i=1}^I O_{ij}$$

(nombre de données pour lesquelles $Y = j$)

Une fois les valeurs espérées calculées, la statistique du χ^2 est obtenue grâce à la formule :

$$\chi^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

Si les effectifs observés sont très proches des effectifs attendus, alors la valeur du χ^2 sera faible, ce qui suggère que les variables sont indépendantes. En revanche, si les écarts sont importants, la valeur du χ^2 sera élevée, ce qui indique une possible relation entre les variables.

P-value

La p-value correspond à la probabilité d'obtenir une valeur du χ^2 au moins aussi élevée que celle observée si l'hypothèse nulle (H_0) est vraie. Dans le test du χ^2 d'indépendance, l'hypothèse nulle suppose que les deux variables sont indépendantes. Une faible p-value indique que les écarts observés entre les données réelles et les données attendues sont peu susceptibles d'être dus au hasard, ce qui suggère l'existence d'une relation entre les variables. Nous considérons une valeur faible lorsqu'elle est inférieure à 0.05 (p-value ≤ 0.05).

Cependant, il faut vérifier ces résultats car avec beaucoup de données, même une relation faible peut donner : p-value ≈ 0 . C'est pourquoi nous utilisons le V de Cramér.

V de Cramér

Le V de Cramér est une mesure statistique qui permet d'évaluer l'intensité de la relation entre deux variables qualitatives. Contrairement à la p-value, qui indique uniquement si une relation existe ou non, le V de Cramér mesure la force de cette relation. Sa valeur est comprise entre 0 et 1. Une valeur proche de 0 (≤ 0.1) indique une association très faible ou inexistante entre les dimensions, tandis qu'une valeur proche de 1 indique une relation forte. Cet indicateur nous permet d'interpréter l'importance réelle du lien observé.

2.6.2 Homophilie

L'homophilie désigne la tendance des individus à établir des relations avec des personnes qui leur ressemblent et qui partagent des caractéristiques similaires. Ce concept, largement étudié en sociologie et en analyse des réseaux, repose sur l'idée que la similarité entre individus favorise la formation et le maintien des liens sociaux. L'homophilie se traduit par le principe selon lequel « la similarité engendre la connexion » (similarity breeds connection). Ainsi, les individus ont davantage tendance à interagir avec des personnes présentant des attributs comparables aux leurs. Pour vérifier cela, nous effectuerons différents tests sur notre réseau.

2.6.2.1 Matrices de transition

L'objectif de ces matrices est de quantifier les probabilités de connexion entre types dans le réseau. Pour chaque paire de dimensions ($src_dim \rightarrow tgt_dim$), nous construisons une matrice qui répond à la question :

"Étant donné qu'un noeud u possède la valeur $from_val$ sur la dimension source, quelle est la probabilité que son voisin v possède la valeur to_val sur la dimension cible?"

Comme nous possédons 4 dimensions (nos 4 lettres), nous aurons au total 16 matrices, chacune de dimensions 2x2 ou 3x3 selon si nous gardons la valeur "Unknown" ou non dans nos calculs.

Pour chaque arête (u, v) du graphe G , nous comptabilisons les co-occurrences de valeurs entre dimensions. Pour chaque paire de dimensions (src_dim, tgt_dim) et chaque valeur source $from_val$:

$$C(src_dim, tgt_dim, from_val, to_val) = \sum_{(u,v) \in E} 1[u_{src} = from_val] \cdot 1[v_{tgt} = to_val]$$

Et le total des liens partant de $from_val$:

$$C_{total}(src_dim, tgt_dim, from_val) = \sum_{to_val} C(src_dim, tgt_dim, from_val, to_val)$$

Chaque cellule (r, c) de la matrice représente la probabilité conditionnelle :

$$P(to_val_c | from_val_r) = \frac{C(src_dim, tgt_dim, from_val_r, to_val_c)}{C_{total}(src_dim, tgt_dim, from_val_r)}$$

Ce qui donne, pour chaque ligne r , une distribution de probabilité normalisée :

$$\sum_c P(to_val_c | from_val_r) = 1$$

Le lift

Afin d'évaluer notre distribution, nous calculons le lift qui mesure le rapport entre la probabilité observée et la probabilité attendue par hasard.

Pour évaluer si une transition est sur ou sous-représentée, nous calculons la distribution marginale, c'est-à-dire la fréquence observée de chaque valeur cible (toutes sources confondues) :

$$P_{marg}(to_val_c) = \frac{\sum_r C(src_dim, tgt_dim, from_val_r, to_val_c)}{\sum_r C_{total}(src_dim, tgt_dim, from_val_r)}$$

Nous pouvons ensuite calculer le lift :

$$Lift(from_val_r) = \frac{1}{|C|} \sum_c \frac{P(to_val_c | from_val_r)}{P_{marg}(to_val_c)}$$

Avec $|C|$: le nombre de valeurs cibles possibles pour la dimension cible (2 ou 3 dans notre cas)

Nous interprétons le résultat comme cela :

Lift	Signification
$> 1.0\times$	Les noeuds <i>from_val</i> se connectent plus que le hasard ne le prédit
$= 1.0\times$	Distribution conforme au hasard, pas de préférence
$< 1.0\times$	Les noeuds <i>from_val</i> se connectent moins que le hasard ne le prédit

TABLE 21 – Interprétation du coefficient de lift

2.6.2.2 Centralité des degrés

Le degré d'un noeud u mesure simplement le nombre de connexions directes d'un noeud :

$$k_u = \sum_{v \in V} 1[(u, v) \in E]$$

où V est l'ensemble des noeuds et E l'ensemble des arêtes du graphe $G = (V, E)$. Dans notre cas (graphe non-dirigé), cela correspond au nombre de voisins immédiats du noeud u .

Pour chaque dimension dim (4 lettres) et chaque valeur val (E ou I pour dim 1), nous isolons le sous-ensemble de noeuds correspondant :

$$\mathcal{N}(dim, val) = \{u \in V | attr(u, dim) = val\}$$

Degré moyen

Après avoir calculé le degré de chaque noeud, nous pouvons calculer leur moyenne par dimension et par valeur :

$$k_{moy}(dim, val) = \frac{1}{|\mathcal{N}|} \sum_{u \in \mathcal{N}} k_u$$

Avec $|\mathcal{N}|$: le nombre de noeud par dimension et par valeur dans notre réseau.

Degré médian

Pour avoir un autre aperçu et que les valeurs extrêmes n'influencent pas notre jugement, nous calculons aussi la médiane :

$$k_{med}(dim, val) = mediane(\{k_u | u \in \mathcal{N}\})$$

Histogramme

Pour avoir un visuel lisible et cohérent, nous fixons le nombre de "bins" dans notre histogramme à $B = 50$. Nous pouvons donc calculer l'écart entre chaque barre :

$$\Delta b = \frac{k_{max} - k_{min}}{B}$$

Chaque bin b contient donc le nombre de noeuds dont le degré tombe dans l'intervalle $[b_{left}, b_{left} + \Delta b[$:

$$count(b) = |\{u \in \mathcal{N} | b_{left} \leq k_u < b_{left} + \Delta b\}|$$

2.6.2.3 Centralité d'intermédiarité

La centralité d'intermédiarité mesure dans quelle proportion un noeud u se trouve sur les plus courts chemins reliant toutes les autres paires de noeuds du graphe :

$$C_B(u) = \sum_{s \neq u \neq t \in V} \frac{\sigma(s, t | u)}{\sigma(s, t)}$$

où :

- $\sigma(s, t)$ est le nombre total de plus courts chemins entre s et t
- $\sigma(s, t | u)$ est le nombre de ces plus courts chemins passant par u

Nous normalisons notre résultat pour ramener la valeur entre $[0, 1]$ en divisant par le nombre maximum de paires possibles :

$$C_B^{norm}(u) = \frac{C_B(u)}{(|V| - 1)(|V| - 2)/2}$$

Le dénominateur correspond au nombre de paires (s, t) avec $s \neq t \neq u$ dans un graphe non-dirigé. Cette normalisation rend la métrique comparable entre graphes de tailles différentes et interprétable comme une proportion :

- 0 : le noeud n'est sur aucun plus court chemin
- 1 : le noeud est sur tous les plus courts chemins du graphe

2.6.2.4 Centralité de proximité

La centralité de proximité mesure à quel point un noeud est proche de tous les autres noeuds du graphe. Elle est définie comme l'inverse de la distance moyenne aux autres noeuds :

$$C_C(u) = \frac{1}{d(u)} = \frac{|V| - 1}{\sum_{v \neq u \in V} d(u, v)}$$

où $d(u, v)$ est la longueur du plus court chemin (en nombre d'arêtes) entre u et v .

Si :

- $C_C(u) \rightarrow 1$: le noeud est au centre du graphe, joignable en peu de sauts
- $C_C(u) \rightarrow 0$: le noeud est très éloigné du reste du réseau
- $C_C(u) = 0$: le noeud est isolé (aucun chemin vers les autres)

Contrairement au degré et à l'intermédiarité, la closeness suit une distribution quasi-normale : la moyenne et la médiane sont proches.

2.6.2.5 Centralité PageRank

Le PageRank mesure l'importance d'un noeud en fonction de la qualité et de la quantité de ses connexions. Un noeud est important s'il est connecté à d'autres noeuds eux-mêmes importants. La valeur de PageRank de u est définie par l'équation récursive :

$$PR(u) = \frac{1 - \alpha}{|V|} + \alpha \sum_{v \in \mathcal{N}(u)} \frac{PR(v)}{k_v}$$

où :

- $\alpha \in [0, 1]$ est le facteur d'amortissement (fixé à $\alpha = 0.85$ par défaut dans `networkx`)
- $\mathcal{N}(u)$ est l'ensemble des voisins de u
- $k_v = |\mathcal{N}(v)|$ est le degré du nœud voisin v
- $\frac{1-\alpha}{|V|}$ est un terme de téléportation uniforme vers n'importe quel nœud (permet de parcourir des nœuds isolés ou des cycles fermés)

Les valeurs de PageRank forment une distribution de probabilité sur V :

$$\sum_{u \in V} PR(u) = 1$$

Chaque valeur individuelle est donc de l'ordre de $1/|V|$, soit $\approx 10^{-4}$ pour $|V| \approx 11600$ nœuds.

Résolution itérative

Pour résoudre sa récursivité, nous utilisons la méthode des puissances (power iteration) :

Initialisation :

$$PR^{(0)}(u) = \frac{1}{|V|}, \forall u \in V$$

Itération :

$$PR^{(t+1)}(u) = \frac{1-\alpha}{|V|} + \alpha \sum_{v \in \mathcal{N}(u)} \frac{PR^{(t)}(v)}{k_v}$$

Convergence :

L'algorithme s'arrête quand :

$$\sum_{u \in V} |PR^{(t+1)}(u) - PR^{(t)}(u)| < \epsilon$$

avec $\epsilon = 10^{-6}$ par défaut.

2.6.2.6 Centralité du vecteur propre

La centralité du vecteur propre mesure l'importance d'un nœud en tenant compte de l'importance récursive de ses voisins. Un nœud est central s'il est connecté à d'autres nœuds eux-mêmes centraux :

$$C_E(u) = \frac{1}{\lambda} \sum_{v \in \mathcal{N}(u)} C_E(v)$$

où λ est une constante de normalisation.

En notation matricielle, cette équation s'écrit :

$$A \cdot x = \lambda \cdot x$$

où :

- A est la matrice d'adjacence du graphe, avec $A_{uv} = 1$ si $(u, v) \in E$
- x est le vecteur des scores de centralité du vecteur propre
- λ est la valeur propre associée

Le vecteur x recherché est précisément le vecteur propre dominant de A , c'est-à-dire celui associé à la plus grande valeur propre $\lambda_{\max}$.

Résolution itérative

Pour résoudre sa récursivité, nous utilisons la méthode des puissances (power iteration) :

Initialisation :

$$x^{(0)} = \frac{1}{|V|} \mathbf{1}$$

Itération :

$$x^{(t+1)} = \frac{A \cdot x^{(t)}}{\|A \cdot x^{(t)}\|_2}$$

À chaque étape, nous multiplions le vecteur courant par la matrice d'adjacence puis on renormalise.

Convergence :

L'algorithme s'arrête lorsque

$$\|x^{(t+1)} - x^{(t)}\|_{\infty} < \epsilon$$

avec $\epsilon = 10^{-6}$ par défaut ou après 1000 itérations (si la convergence est trop lente).

2.6.2.7 Coefficient de regroupement

Le coefficient de regroupement local d'un noeud u mesure la proportion de paires de voisins de u qui sont eux-mêmes connectés entre eux, autrement dit, à quel point le voisinage de u forme un graphe dense :

$$C_{clust}(u) = \frac{|\{(v, w) \in E \mid v, w \in \mathcal{N}(u)\}|}{k_u(k_u - 1)/2}$$

où :

- $\mathcal{N}(u)$ est l'ensemble des voisins de u
- $k_u = |\mathcal{N}(u)|$ est le degré de u
- $k_u(k_u - 1)/2$ est le nombre maximum de liens possibles entre les voisins de u
- Le numérateur compte les liens effectivement existants entre ces voisins

Regroupement moyen global

Le coefficient de regroupement global du réseau est la moyenne sur tous les noeuds :

$$\bar{C}_{clust} = \frac{1}{|V|} \sum_{u \in V} C_{clust}(u)$$

Il sert de référence pour évaluer si le réseau est plus ou moins regroupé qu'un graphe aléatoire de même densité, pour lequel nous attendrions :

$$\bar{C}_{clust}^{aleatoire} \approx \frac{\langle k \rangle}{|V|}$$

où $\langle k \rangle$ est le degré moyen. Un réseau réel avec $\bar{C}_{clust} \gg \bar{C}_{clust}^{aleatoire}$ présente un fort effet de regroupement (les amis de mes amis sont mes amis).

2.6.2.8 Regroupement vs degré

Nous allons effectuer une comparaison entre le coefficient de regroupement ($C_{clust}(u)$) et le degré (k_u) de chaque noeud. Dans les réseaux hiérarchiques, cette relation suit empiriquement une loi de puissance inverse :

$$C_{clust}(u) \propto k_u^{-\beta}, \quad \beta > 0$$

Cette décroissance s'explique structurellement : un noeud à degré élevé connecte des communautés distinctes dont les membres ne se connaissent pas entre eux, tandis qu'un noeud à faible degré gravite dans un voisinage localement dense.

2.6.2.9 Coefficient du Rich Club

Le Rich Club coefficient mesure la tendance des noeuds les plus connectés à former un club exclusif en se connectant préférentiellement entre eux. Pour un seuil de degré k , il est défini comme :

$$\varphi(k) = \frac{2 \cdot |E_{>k}|}{|\mathcal{V}_{>k}| \cdot (|\mathcal{V}_{>k}| - 1)}$$

où :

- $\mathcal{V}_{>k} = \{u \in V \mid k_u > k\}$ est l'ensemble des noeuds ayant un degré strictement supérieur à k
- $|E_{>k}|$ est le nombre de liens effectivement existants entre les noeuds de $\mathcal{V}_{>k}$
- $|\mathcal{V}_{>k}| \cdot (|\mathcal{V}_{>k}| - 1)/2$ est le nombre maximum de liens possibles entre ces noeuds

$\varphi(k)$ est donc la densité du sous-graphe induit par les noeuds de degré supérieur à k .

2.6.3 Hétérophilie

L'hétérophilie correspond à la tendance des individus à nouer des relations avec des personnes présentant des caractéristiques différentes des leurs. Ce concept renvoie au degré de différence existant entre les individus engagés dans une interaction. L'hétérophilie favorise les échanges entre groupes ou catégories distincts et peut contribuer à la circulation d'idées, de comportements ou de ressources variées. Dans le cadre de l'analyse des types de personnalités, elle se manifeste par la présence d'individus appartenant à des profils différents ou opposés. Pour notre analyse, nous allons donc regarder la répartition des profils MBTI dans nos films de base.

2.6.3.1 Score d'hétérophilie

Préparation des données

Pour chaque film, on extrait les $n = 10$ premiers acteurs du casting. Cette liste $A_{\text{film}} = \{a_1, \dots, a_{10}\}$ est ensuite croisée avec la base de données MBTI :

$$A_{\text{matched}} = A_{\text{film}} \cap A_{\text{MBTI}}$$

où A_{MBTI} est l'ensemble des acteurs disposant d'un type MBTI renseigné. On ne conserve que les films ayant au moins 2 acteurs matchés, les films à 0 ou 1 match étant écartés car insuffisants pour mesurer une diversité.

Pour chaque film et chaque axe MBTI (E/I, S/N, T/F, J/P), on dénombre les occurrences de chaque lettre parmi les acteurs matchés :

$$c_E = |\{a \in A_{\text{matched}} \mid \text{letter}_1(a) = E\}|, \quad c_I = |A_{\text{matched}}| - c_E$$

La proportion de la première lettre de chaque axe est calculée sur le total d'acteurs matchés pour ce film :

$$p(\text{lettre}) = \frac{c_{\text{lettre}}}{c_{\text{lettre}} + c_{\text{lettre_complementaire}}}$$

Ce qui donne pour chaque film 4 proportions $p_E, p_S, p_T, p_J \in [0, 1]$ (et les proportions complémentaires $p_I = 1 - p_E$, etc.). Pour chaque film, nous lui attribuons ainsi un profil MBTI correspondant à la lettre présente en plus grande proportion.

Entropie

Le calcul repose sur l'entropie de Shannon d'une variable binaire, qui mesure l'incertitude ou la diversité d'une distribution à deux issues :

$$H(p) = -[p \log_2(p) + (1 - p) \log_2(1 - p)]$$

Cette fonction possède deux propriétés :

$$H(p) = \begin{cases} 0 & \text{si } p = 0 \text{ ou } p = 1 \quad (\text{film monotype}) \\ 1 & \text{si } p = 0.5 \quad (\text{équilibre parfait 50/50}) \end{cases}$$

L'entropie est donc normalisée entre $[0, 1]$ pour une variable binaire. Nous remarquons que les films avec seulement un ou aucun acteur match ($|A_{\text{matched}}| \leq 1$) nous donneraient une entropie de 0, c'est pourquoi nous avons pris le soin de les retirer précédemment.

Score

Le score final agrège l'entropie des 4 axes par une moyenne arithmétique simple :

$$\text{hetero_score}(\text{film}) = \frac{1}{4} [H(p_E) + H(p_S) + H(p_T) + H(p_J)]$$

Ce score hérite des bornes de l'entropie :

$$\text{hetero_score} \in [0, 1]$$

avec l'interprétation suivante :

$$\text{Catégorie}(\text{film}) = \begin{cases} \text{Homogène} & \text{hetero_score} < 0.25 \\ \text{Mixte} & 0.25 \leq \text{hetero_score} \leq 0.75 \\ \text{Hétérogène} & \text{hetero_score} > 0.75 \end{cases}$$

2.6.3.2 Formation de communautés

Distribution globale et correction du biais

Avant de comparer les films entre eux, nous établissons une baseline globale : la proportion de chaque lettre MBTI sur l'ensemble des acteurs matchés, toutes apparitions confondues :

$$\bar{p}_E = \frac{\sum_{\text{film}} n_E(\text{film})}{\sum_{\text{film}} (n_{\text{total}}(\text{film}) - n_{\text{undef}}(\text{film}))}$$

et de façon identique pour $\bar{p}_S, \bar{p}_T, \bar{p}_J$. Cette baseline représente la fréquence naturelle de chaque type dans la population d'acteurs étudiée. Cette fréquence n'est généralement pas 0.5, car certains types peuvent être surreprésentés dans le métier d'acteur.

Pour isoler la spécificité de chaque film indépendamment du biais de population, nous calculons un écart centré :

$$\delta_E(\text{film}) = p_E(\text{film}) - \bar{p}_E$$

et de façon analogue pour $\delta_S, \delta_T, \delta_J$. Ce centrage permet de ne pas dire qu'un film serait "orienté E" simplement parce que la population d'acteurs est globalement plus E que I, sans refléter un penchant pour un type.

$$\delta_X(\text{film}) \in [-\bar{p}_X, 1 - \bar{p}_X]$$

On distingue 3 cas :

- $\delta_X > 0$: le film surreprésente la lettre X par rapport à la moyenne du corpus
- $\delta_X = 0$: le film reflète exactement la distribution moyenne
- $\delta_X < 0$: le film sous-représente X

Ce sont ces 4 deltas ($\delta_E, \delta_S, \delta_T, \delta_J$) qui constituent le vecteur de profil 4D utilisé pour tout le clustering qui suit.

Classification des films

Pour chaque axe, nous assignons au film la lettre majoritaire parmi ses acteurs :

$$\text{dom}(p, X, Y) = \begin{cases} X & \text{si } p > 0.5 \\ Y & \text{si } p < 0.5 \\ = & \text{si } p = 0.5 \quad (\text{égalité parfaite}) \end{cases}$$

La concatenation des 4 lettres dominantes forme un "type MBTI agrégé du film" :

$$\text{community_dominant}(\text{film}) = \text{dom}_{EI} \oplus \text{dom}_{SN} \oplus \text{dom}_{TF} \oplus \text{dom}_{JP}$$

où $\oplus$ dénote la concaténation de chaînes. Cela génère au maximum $3^4 = 81$ communautés possibles (2 lettres + le symbole par axe).

K-Means

K-Means partitionne les n films en k clusters en minimisant l'inertie intra-cluster :

$$J(k) = \sum_{i=1}^k \sum_{\mathbf{x} \in C_i} \|\mathbf{x} - \boldsymbol{\mu}_i\|^2$$

où $\boldsymbol{\mu}_i$ est le centroïde du cluster C_i :

$$\boldsymbol{\mu}_i = \frac{1}{|C_i|} \sum_{\mathbf{x} \in C_i} \mathbf{x}$$

L'algorithme alterne itérativement entre assignation (chaque point au centroïde le plus proche) et mise à jour (recalcul des centroïdes), jusqu'à convergence.

On effectue cette méthode en faisant varier notre nombre de cluster et on utilise ensuite la méthode du coude pour sélectionner le nombre de cluster optimal. L'inertie $J(k)$ décroît monotonement avec k (plus de clusters réduit toujours l'inertie). On utilise alors la librairie [kneed](#) pour détecter le point de courbure maximale sur la courbe $(k, J(k))$.

DBSCAN

DBSCAN regroupe les points en se basant sur la densité locale : un point appartient à un cluster s'il a suffisamment de voisins proches. Les points trop isolés sont étiquetés comme bruit (-1).

Nos données étant issues de proportions sur de petits échantillons. Nous produisons un nuage de points continus et relativement uniforme dans l'espace, sans vraies "poches de densité" séparées par des zones vides. Nous pouvons voir que pour notre partitionnement, nous obtenons par ordre décroissant :

Nom du cluster	Nombre de films
Groupe 0	2263
Groupe -1 (bruit)	121
Groupe 12	24
Groupe 15	21
Groupe 19	21

TABLE 22 – Répartitions des films par cluster avec DBSCAN

Nous remarquons très franchement dans nos résultats que cette méthode n'est pas adapté pour notre situation et nous abandonnerons donc cette méthode.

Louvain

Louvain détecte des communautés en maximisant la modularité sur un graphe : il regroupe les noeuds qui ont plus de connexions internes que ce qu'on attendrait par hasard. Le graphe est construit en reliant les films dont la distance euclidienne est sous un certain seuil.

Cette méthode est conçu pour des réseaux où les connexions sont des données primaires. Dans notre cas, le graphe est entièrement dérivé d'une distance euclidienne sur seulement 4 dimensions. En jouant sur les paramètres de notre méthode, nous sommes arrivé à un partitionnement en ~ 29 communautés mais qui étaient de taille souvent similaire. Ces résultats indique une formation de groupe plutôt aléatoire et non pertinent, c'est pourquoi nous avons continuer uniquement avec la méthode [K-means](#).

3 Resultats

3.1 Homophilie

Pour analyser notre réseau, nous regarderons les liens existant entre les différents types de personnalité pour savoir s'il existe un lien entre des personnes similaires. Nous distinguerons deux cas : avec et sans les personnes dont nous ne connaissons pas leurs traits de personnalité.

3.1.1 Réseau complet

Pour cette partie, nous considérerons tout notre réseau en attribuant la valeur "Unknown" lorsqu'un noeud n'aura pas de valeur pour la personnalité.

3.1.1.1 Transition

Pour commencer, nous regardons la distribution des liens en partant d'un attribut vers tous les autres. Comme nous possédons 4 lettres définissant la personnalité contenant chacun 3 valeurs (2 lettres + "Unknown"), nous obtenons 16 matrices de distribution de taille 3×3 . Nous y incluons également le calcul du [lift](#) pour évaluer l'importance de ces résultats.




FIGURE 19 – Matrices de transition (tout le réseau)

Dans toutes nos matrices, nous remarquons une dominance de la catégorie "Unknown" qui s'explique par la majorité de noeud étant inconnu comme vu dans la [jointure](#). Nous notons, cependant, un lift plus élevé pour nos lettres définies et plus bas pour "Unknown" qui indique une présence plus importante des valeurs définies et qui peut s'expliquer par une plus grande importance des noeuds connus qui sont généralement des acteurs plus connus et récurrents.

3.1.1.2 Centralité des degrés

En analysant le degré des nos noeuds en fonction de leur personnalité, nous pourrions rapidement remarquer un paterne dans notre distribution. Comme précédement, nous possédons 3 valeurs par dimension et 4 dimensions (4 lettres) donc nous obtenons 12 graphiques :




FIGURE 20 – Distribution des degrés (tout le réseau)

Comme attendu, toutes nos courbes sont décroissantes avec beaucoup de noeuds contenant peu de liens et moins de noeuds au fur et à mesure que nous augmentons notre degré. La différence majeure se situe sur les graphiques de la valeur "Unknown", où, bien que beaucoup plus nombreux (9191 noeuds contre ~ 2500), nous obtenons une médiane $\sim 3x$ plus petite que celle des noeuds définis. Nous pouvons donc en conclure que les noeuds non-définis sont des acteurs avec moins de collaborations et donc certainement des acteurs moins connus et moins populaires.

3.1.1.3 Centralité d'intermédierité

La betweenness centrality d'un noeud mesure à quel point il se trouve "sur le chemin" entre d'autres noeuds dans un réseau. Si sa valeur vaut 0, le noeud n'est sur aucun chemin entre les autres. Comme attendu dans la plupart des réseaux réels, la plupart des noeuds sont "ordinaires" et ne représente pas de lien central.




FIGURE 21 – Distribution de l'intermédierité (tout le réseau)

Nous notons que la médiane pour les lettres "Unknown" se trouve à 0 et soutient l'hypothèse que les noeuds dont nous ne connaissons pas les valeurs se situe sur la périphérie de notre réseau. La valeur plutôt basse de la betweenness correspond aussi bien à un réseau naturel qui ne possède que quelques points centraux.

3.1.1.4 Centralité de proximité

La closeness centrality mesure à quel point un noeud est proche de tous les autres dans le réseau. La proximité suit généralement une distribution normale, ce qui signifie que les noeuds sont relativement homogènes.




FIGURE 22 – Distribution de proximité (tout le réseau)

Sur nos graphiques, nous notons un pic à 0 qui représente des noeuds isolés (composantes déconnectées du graphe). Cette pointe est beaucoup plus élevée dans les graphiques "Unknown" étant donné que ces noeuds sont situés en périphérie du réseau et donc plus souvent isolés. Le reste de notre courbe illustre bien une distribution normale autour de la médiane située au alentour de ~ 0.29 (~ 0.26 pour "Unknown"). Ces différences sont minimes et suggère que le type MBTI n'a que peu d'influence sur la position structurale dans le réseau.

3.1.1.5 Centralité PageRank

Dans la continuité de nos résultats précédents, nos graphiques de PageRank montre un pic initial élevé puis une décroissance progressive avec une longue queue. C'est la signature d'un réseau où quelques noeuds accumulent beaucoup d'influence.




FIGURE 23 – Distribution du PageRank (tout le réseau)

Comme pour la proximité, leur médiane se situe très proche (~ 0.0001) et indique que le type MBTI n'influence pas structurellement le PageRank médian. La médiane des graphes "Unknown" a une valeur 2x plus petite qui montre bien que ces noeuds se situent en périphérie sur toutes les métriques.

On remarque que les lettres : E, S, T, P ont une distribution qui s'étend jusqu'à 0.0012. Cela signifie que dans ces groupes, quelques noeuds ont une influence disproportionnée bien au-delà

de la médiane et qui correspond au profil de Samuel L. Jackson (le noeud le plus central de notre réseau).

3.1.1.6 Centralité du vecteur propre

La centralité du vecteur propre mesure l'influence d'un noeud en tenant compte de l'influence de ses voisins donc un noeud dans un groupe dense de noeuds influents explose en valeur.




FIGURE 24 – Distribution du vecteur propre (tout le réseau)

Comme pour nos autres mesures, la médiane est similaire pour les lettres définies (~ 0.005) et inférieur pour les "Unknown". On peut souligner une médiane légèrement plus élevée pour les lettres : I, N, T qui indique que leurs connexions sont peut-être plus "qualitatives", cependant la différence est infime.

3.1.1.7 Coefficient de regroupement

Ici, nous regardons à quel point les voisins d'un noeud sont eux-mêmes connectés entre eux. Pour une meilleure interprétation, nous allons mettre deux métriques en relation simultanément. Nous ne regardons plus une distribution isolée mais une loi structurelle du réseau.




FIGURE 25 – Comparaison du regroupement en fonction du degré (tout le réseau)

Nous voyons une courbe en hyperbole, signature d'un réseau invariant d'échelle (réseau scale-free). Nous notons un plateau avec un clustering de 1 pour des degrés < 10 à l'exception de quelques points en $(0, 0)$ qui sont des points isolés du réseau. Nous voyons clairement une prédominance des points "Unknown" dans les degrés < 100 . Les différentes lettres se superposent parfaitement sur la même courbe dans les 4 graphiques, ainsi aucun type MBTI ne se distingue.

Entre degré 10 et 30, Nous avons une grande variabilité de clustering (0.3 à 0.9). Des noeuds avec un degré similaire mais des rôles très différents : certains dans des cliques fermées, d'autres déjà en train de ponter des communautés.

3.1.1.8 Coefficient du Rich Club

Le Rich Club mesure si les noeuds très connectés ont tendance à se connecter entre eux plutôt qu'avec des noeuds moins connectés.




FIGURE 26 – Rich Club selon le degré (tout le réseau)

Notre courbe monte continuellement de 0 à 1, c'est la signature d'un effet Rich Club progressif et robuste. Nous remarquons une augmentation brutale entre les degrés 228 et 240 : ϕ passe de 0.4 à 1.0. Cela signifie qu'il existe un petit groupe de super-hubs qui forment une clique quasi-parfaite entre eux. Les oscillations entre 180 et 200 degré indique que peu de noeuds sont présents à ces degrés élevés et du coup chaque noeud ajouté ou retiré du club a un impact visible sur $\phi(k)$.

3.1.2 Réseau sans inconnu

Comme la majorité des noeuds sont inconnus, Nous abandonnons tous les noeuds dont nous ignorons les données MBTI pour se focaliser uniquement sur ceux connus.

	Avant filtrage		Après filtrage	
Métrique	Quantité	%	Quantité	%
Nœuds	11 637	100.0%	2 446	21.0%
Liens	111 290	100.0%	26 126	23.5%

TABLE 23 – Comparaison du graphe avant et après filtrage

Avec cette analyse uniquement sur des données connues, nous espérons repérer un lien qui pourrait ne pas être visible avec les noeuds "Unknown".

3.1.2.1 Transition

Comme nous n'avons plus de noeuds inconnus dans notre nouveau réseau, nous pouvons représenter les matrices de transitions en taille 2×2 pour repérer de potentiels liens.




FIGURE 27 – Matrices de transition (réseau filtré)

Pour nos 16 matrices de transitions, nous remarquons instantanément que le [lift](#) est toujours de 1 pour toutes nos lettres, ce qui signifie que la probabilité de transition observée est exactement égale à la probabilité attendue par hasard. Nous avons donc un résultat clair qui n'indique aucun lien et donc une indépendance entre les transitions et les dimensions MBTI.

3.1.2.2 Centralité des degrés

En regardant la distribution des degrés avec notre réseau filtré, nous pouvons nous attendre à avoir une loi de puissance typique des réseaux de collaboration comme pour nos résultats globaux, avec une grande majorité d'acteurs qui ont un faible degré et une minorité d'acteurs très connectés.




FIGURE 28 – Distribution des degrés (réseau filtré)

Nous notons que la médiane de toutes nos lettres se situe autour de 12 degrés. Cette valeur étant partagée par toutes nos dimensions, nous pouvons donc dire que le degré de nos noeuds n'est pas influencé par les données MBTI. Autrement, aucun signe anormal n'apparaît et donc pas de liens sur le degré de nos noeuds.

3.1.2.3 Centralité d'intermédierité

Comme pour nos résultats sur le réseau complet, nous nous attendons à une distribution de la centralité d'intermédierité avec un pic concentré près de zéro suivie d'une queue droite très étalée (loi de puissance). Cette morphologie est cohérente avec la structure scale-free identifiée lors de l'analyse des degrés.




FIGURE 29 – Distribution de l'intermédierité (réseau filtré)

Les médianes, comprises autour de 0.0001, sont extrêmement faibles et uniformes d'un type à l'autre. Cette homogénéité confirme que le profil MBTI d'un acteur n'est pas associé à une position structurelle particulière dans le réseau de collaborations.

Certains acteurs atteignent des valeurs de d'intermédierité de l'ordre de 0.01 à 0.02, soit cent à deux cents fois la médiane. Leur répartition entre types MBTI ne révèle pas de surreprésentation notable d'un profil particulier, ce qui renforce l'hypothèse d'une indépendance entre personnalité

et rôle structural.

3.1.2.4 Centralité de proximité




FIGURE 30 – Distribution de la proximité (réseau filtré)

Toutes les distributions affichent une forme en cloche relativement symétrique, centrée autour de la médiane de 0.31–0.32, sans queue lourde prononcée. Cette morphologie gaussienne indique que les acteurs du réseau filtré sont globalement équidistants les uns des autres : il n'existe pas d'acteurs structurellement beaucoup plus proches du reste du réseau que la moyenne. Comme pour le degré et l'intermédiarité, toutes les médianes sont comprises dans un intervalle extrêmement étroit.

Le réseau présente ainsi une propriété de petit monde, caractéristique des réseaux de collaboration professionnelle. Un pic secondaire visible vers 0 est commun à toutes les distributions. Il correspond aux acteurs situés dans des composantes isolées ou faiblement connectées. Ce pic étant plus significatif que celui présent avec le réseau complet s'explique par la réduction significative du graphe lors du filtrage qui a pu fragmenter certaines connexions périphériques.

La centralité de proximité apporte une confirmation supplémentaire à l'ensemble des résultats précédents : la proximité d'un acteur est indépendante de son profil MBTI.

3.1.2.5 Centralité PageRank




FIGURE 31 – Distribution du PageRank (réseau filtré)

La distribution du PageRank présente une forme intermédiaire entre celles observées pour la centralité d'intermédiarité et de proximité. Nous retrouvons le pic initial caractéristique des distributions à queue lourde mais avec une décroissance plus progressive et une queue moins extrême. Les médianes sont remarquablement concentrées autour de 0.00028-0.00029.

Les types I, N, T affichent systématiquement des médianes de [PageRank](#) légèrement supérieures à leurs opposés, contrairement à la 4ème lettre (J, P) qui ont une médiane similaire. Ce pattern suggère que ces lettres tendent à être connectés à des voisins légèrement mieux connectés, ce qui se traduit par un PageRank marginalement plus élevé. Bien que cet écart soit plus marqué jusqu'ici, il reste d'une amplitude très faible et ne permet pas de conclure à une différence structurelle significative liée au profil MBTI.

3.1.2.6 Centralité du vecteur propre




FIGURE 32 – Distribution du vecteur propre (réseau filtré)

La distribution de la centralité de vecteur propre présente une forme similaire à celle du PageRank. Les médianes s'inscrivent autour de 0.006. On retrouve la même tendance marginale : les types I, N, T et P affichent des médianes légèrement supérieures à leurs opposés. Comme pour le PageRank, cette différence est faible et ne permet pas de conclure à une différence structurelle significative liée au profil MBTI.

3.1.2.7 Coefficient de regroupement




FIGURE 33 – Regroupement en fonction du degré (réseau filtré)

La relation observée est identique sur l'ensemble des dimensions : une décroissance hyperbolique nette du coefficient de clustering à mesure que le degré augmente, conformément au comportement attendu dans les réseaux de collaboration de type petit monde et à nos résultats avec le [réseau complet](#).

La courbe de décroissance entre les deux lettres de chaque dimension se mélangent de manière indiscernable sur toute la plage de degrés. Ce résultat constitue la confirmation la plus directe et la plus visuelle de l'indépendance entre profil MBTI et structure du réseau. Les acteurs à faible degré présentent des coefficients de clustering très variables, allant de 0 à 1. Cette variabilité s'explique mécaniquement : un acteur ayant joué dans un seul film avec deux partenaires a un clustering de 1 si ces deux partenaires ont aussi tourné ensemble, et de 0 sinon.

À mesure que le degré augmente, le coefficient converge vers des valeurs stables autour de 0.1 pour les degrés supérieurs à 50. Les acteurs ayant collaboré avec plus de 75 partenaires distincts maintiennent un clustering résiduel non nul, ce qui indique que leurs collaborateurs continuent de se croiser entre eux à une fréquence supérieure au hasard. C'est la signature classique d'un réseau de collaboration professionnelle.

La rangée de points à coefficient exactement égal à 0 (ou 1) pour des degrés très faibles correspond aux acteurs ayant exclusivement tourné dans un seul film étant le seul acteur connu du film (ou avec un groupe entièrement interconnecté).

3.1.2.8 Coefficient du Rich Club




FIGURE 34 – Rich Club en fonction du degré (réseau filtré)

La courbe présente une croissance quasi continue $\varphi(k) \approx 0.01$ pour les faibles degrés jusqu'à $\varphi(k) \approx 0.40$ autour de $k = 110$ avant d'atteindre un pic à $\varphi(k) \approx 0.70$ pour $k \approx 120$. Cette progression monotone est la signature d'un phénomène de club riche : plus on restreint l'analyse aux acteurs les mieux connectés, plus ces derniers tendent à avoir collaboré entre eux.

Les fluctuations observées entre $k = 110$ et $k = 135$ (pic à 0.70 suivi d'une chute brutale à 0) sont un artefact statistique lié au très faible nombre de noeuds restants dans cet intervalle. Lorsque le sous-ensemble ne contient plus que quelques acteurs, l'ajout ou la suppression d'un seul lien fait varier $\varphi(k)$ de manière discontinue. La chute à 0 pour $k > 135$ indique qu'il ne reste plus qu'un ou deux acteurs isolés à ce niveau de degré, rendant le coefficient non calculable de manière significative.

3.2 Hétérophilie

Pour l'hétérophilie, nous regarderons la répartition des profils MBTI parmi les films sélectionnés.

Catégorie	Nombre de films	Proportion (%)
Nombre total de films	2 826	100.0 %
Films avec 2+ acteurs avec MBTI	2 417	85.53 %
Films avec 1 acteur avec MBTI	209	7.40 %
Films sans correspondance MBTI	200	7.08 %

TABLE 24 – Répartition des films selon la disponibilité des correspondances MBTI

3.2.1 Distribution par film

Nous pouvons nous intéresser à la distribution de la proportion de chaque lettre par film :




FIGURE 35 – Distribution de chaque lettre par film

Nos graphiques ont une forme multimodale prononcée sur les quatre dimensions, contrastant nettement avec une distribution unimodale centrée sur 0.5 qui aurait signalé un mélange homogène et systématique des types au sein des castings.

Sur les quatre axes, nous observons une concentration marquée aux extrémités et au centre de la distribution accompagnée de pics secondaires. Ce motif s'explique par la taille réduite de certains castings : avec seulement 2 ou 3 acteurs matchés au MBTI, les proportions possibles sont nécessairement discrètes (0, 0.33, 0.5, 0.67, 1). Les moyennes par axe reproduisent fidèlement le biais de la base MBTI source.

Catégorie	Distr. E (%)	Distr. S (%)	Distr. T (%)	Distr. J (%)
Distribution par acteur	56.9 %	41.8 %	39.9 %	41.8 %
Distribution par film	56 %	42 %	41 %	42 %

TABLE 25 – Comparaison de la distribution des profils MBTI par acteur et par film

Aucun des quatre axes ne présente de concentration franche autour d'un point. La composition MBTI d'un casting résulte davantage du hasard de l'échantillonnage sur un petit nombre d'acteurs que d'une logique volontaire de diversité ou d'homogénéité de personnalité.

3.2.2 Score d'hétérophilie

Nous pouvons maintenant regarder notre répartition selon notre [score d'hétérophilie](#) :

Statistique	Valeur
Nombre de films	2 417
Moyenne score	0.747
Écart-type	0.204
Minimum	0.000
1er quartile (25%)	0.656
Médiane (50%)	0.811
3e quartile (75%)	0.909
Maximum	1.000

TABLE 26 – Statistiques descriptives du score d'hétérophilie

Catégorie	Nombre de films	Proportion (%)
Très homogènes (score < 0.25)	60	2.5%
Mixtes ($0.25 \leq \text{score} \leq 0.75$)	1 005	41.6%
Très hétérogènes (score > 0.75)	1 352	55.9%

TABLE 27 – Répartition des films par catégorie d'hétérophilie

La moyenne de 0.747, nettement supérieure au point médian théorique de 0.5, indique une tendance générale des castings vers la mixité des profils MBTI plutôt que vers l'homogénéité. Plus de la moitié des films (55.9%) affichent un score supérieur à 0.75, contre seulement 2.5% de films très homogènes. Nous avons donc une distribution très diverse, ce qui montre que les groupes d'acteurs ne sont pas corrélés avec leur profil MBTI.




FIGURE 36 – Boîte à moustache de la dispersion et distribution du score d'hétérophilie

Les boîtes à moustaches montrent une dispersion quasi identique sur les quatre axes, avec des médianes proches de 0.40 – 0.50 et des quartiles quasiment symétriques. L'axe E/I présente la médiane la plus proche de l'équilibre parfait, tandis que les axes S/N, T/F et J/P affichent une médiane légèrement inférieure, reflet direct du biais de base de la [dataset MBTI](#) déjà identifié. Cette cohérence confirme que le score d'hétérophilie composite n'est pas tiré par un axe en particulier, mais reflète un comportement homogène des quatre dimensions.

L'histogramme du score d'hétérophilie révèle une structure bimodale : un premier pic autour de 0.5 et un second plus large et plus élevé autour de 0.9. Le second mode domine numériquement, expliquant la moyenne élevée. Cette bimodalité suggère l'existence de deux régimes de casting distincts : des films avec une composition MBTI relativement tranchée sur certains axes et des films dont le casting, généralement plus large, atteint une mixité quasi maximale sur l'ensemble des quatre dimensions.




FIGURE 37 – Score d’hétérophilie en fonction du nombre d’acteurs par film

Parmi les points opposant le score d’hétérophilie au nombre d’acteurs matchés révèle un phénomène attendu de réduction de variance avec l’effectif. Pour les films à très faible effectif, le score ne peut prendre que des valeurs discrètes extrêmes (0, 0.25, 0.5, 0.75, 1). À mesure que l’effectif augmente, la dispersion des scores se resserre progressivement vers le haut de l’échelle, et les scores inférieurs deviennent rares. Ce graphique indique clairement une tendance à l’hétérogénéité pour nos groupes d’acteurs à mesure que leur taille augmente.

3.2.3 Formation de communautés

Pour repérer de potentielles communautés, nous allons attribuer des profils à chaque film. Etant donné que plusieurs dimensions MBTI peuvent avoir une même proportion dans notre base de film, nous vérifions que ce ne soit pas une majorité :

Axe	Nombre de films	Proportion (%)
E/I	456	17.36 %
S/N	470	17.90 %
T/F	429	16.34 %
J/P	438	16.68 %
Au moins 1 égalité	1 029	39.19%

TABLE 28 – Nombre de films présentant une égalité de proportion par axe MBTI

Nous notons tout de même que pratiquement 40% des films possèdent au moins une égalité sur une dimension. C’est pourquoi, en cas d’égalité, nous ne noterons pas de lettres mais le symbole : "=".

3.2.3.1 Distribution des films par profils MBTI

Avec la valeur "=" pour remplacer la lettre dans notre profil MBTI, nous obtenons cette distribution :




FIGURE 38 – Distribution des film par lettre dominante

Nous remarquons que malgré un nombre conséquent d'égalité, le profil **ENFP** se distingue en étant le plus présent et quasiment 2x plus que la deuxième occurrence. Sur les dix profils les plus fréquents, aucun ne présente d'égalité et montre tout de même une tendance définie. Le profil, possédant au moins une égalité, le plus présent est le **E=FP** qui correspond aussi au profil le plus présent (**ENFP**).

3.2.3.2 K-means

Lors de nos calculs pour le k-means, nous remarquons que nous obtenons effectivement une courbe décroissante et la méthode du coude nous indique que d'avoir $k = 5$ groupes serait le meilleur compromis pour notre cas.




FIGURE 39 – Méthode du coude sur l'inertie en fonction du nombre de groupe

Afin d'avoir des résultats pertinent, nous n'allons pas simplement regarder les profils MBTI mais les standardiser et voir quel profil apparaît plus que prévu dans chaque groupe :

Cluster	E	S	T	J
0	-0.063	0.325	0.065	-0.192
1	0.166	0.113	-0.137	0.285
2	-0.291	-0.142	-0.197	0.094
3	0.215	-0.176	-0.052	-0.204
4	-0.072	-0.080	0.306	0.087

TABLE 29 – Profil moyen standardisé par cluster K-Means (k=5)

Lorsque nos valeurs sont positifs, elles signifient que la lettre est plus présente que prévu et inversement pour nos valeurs négatives. Plus nous nous rapprochons de 0 et moins cette proportion est significative. Nous obtenons donc ces 5 profils qui apparaissent plus que prévu pour chaque cluster :

Cluster	Label MBTI
0	ISTP
1	ESFJ
2	INFJ
3	ENFP
4	INTJ

TABLE 30 – Labels MBTI associés à chaque cluster K-Means

Nous pouvons représenter ces tendances sur 2 dimensions en croisant chacune de nos 4 dimensions initiales et ainsi obtenir 6 graphiques avec les centroïdes de nos données.




FIGURE 40 – Répartition des groupes par pair de dimension

Nous notons que malgré certains points dispersés, les centroïdes se situent tous autour du centre (0, 0) dans toutes les dimensions et indique donc qu'aucune tendance notable n'est présente dans ces communautés.

4 Discussion et travail futur

L'ensemble des analyses menées convergent vers un constat unique et robuste : le type de personnalité MBTI ne constitue pas un facteur organisateur des collaborations entre acteurs sur la période de 1990 à 2009. Le fait que toutes les analyses, menées selon des angles méthodologiques différents, pointent indépendamment vers la même conclusion renforce la fiabilité de cette absence de lien.

Plusieurs hypothèses peuvent être avancées pour interpréter ce résultat. Premièrement, le processus de casting cinématographique répond à des contraintes commerciales, artistiques et logistiques qui n'ont a priori aucune raison de corrélérer avec un trait de personnalité MBTI. Deuxièmement, la donnée MBTI utilisée provient de sources déclaratives en ligne, potentiellement biaisées tant dans leur couverture que dans leur fiabilité.

Le travail sur l'hétérophilie complète cette analyse en montrant que les castings de films présentent une mixité de profils MBTI supérieure à ce qu'une répartition homogène aurait laissé supposer. La formation de communautés par K-Means a permis d'isoler cinq profils de casting récurrents mais l'analyse des centroïdes a révélé que ces groupes restent proches du centre de l'espace standardisé, signe d'une structuration faible plutôt que de communautés franchement différenciées.

Plusieurs pistes pourraient être explorées pour approfondir ou affiner les résultats obtenus dans ce projet. Une première direction consisterait à étendre la période d'analyse au-delà des années 1990-2010, afin de vérifier si les conclusions d'indépendance entre profil MBTI et structure du réseau se maintiennent sur d'autres décennies, ou si elles sont spécifiques au contexte cinématographique de cette période.

Une deuxième direction consisterait à analyser le profil de personnalité par un autre biais que le profil MBTI, afin de déterminer si d'autres facteurs psychologiques négligés par le MBTI pourraient avoir de l'influence.

Enfin, il serait pertinent d'étudier des unités d'analyse plus fines que le film, par exemple en construisant un réseau en intégrant la dimension du réalisateur comme variable de contrôle, afin de vérifier si un lien entre personnalité et collaboration émerge ou en prenant en compte la totalité des acteurs de chaque film.

5 Conclusion

Ce projet avait pour objectif d'étudier l'existence d'un lien entre le type de personnalité MBTI des acteurs et la structure du réseau de collaborations cinématographiques sur la période 1990-2009, à travers deux approches complémentaires : l'homophilie mesurée par l'analyse de la position structurelle des acteurs dans le réseau et l'hétérophilie mesurée par la composition en profils MBTI au sein de chaque film.

L'analyse d'homophilie, menée à la fois sur le réseau complet et sur le réseau filtré aux seuls acteurs disposant d'une donnée MBTI connue, n'a révélé aucun lien significatif entre le profil de personnalité et la position structurelle d'un acteur dans le réseau. Les matrices de transition ont systématiquement affiché des valeurs de lift proches de 1, signalant une indépendance statistique entre les dimensions MBTI des acteurs en collaboration. Cette absence de lien s'est confirmée à travers l'ensemble des sept métriques structurelles étudiées : le degré, la centralité d'intermédiarité, la centralité de proximité, le PageRank, la centralité du vecteur propre, le coefficient de regroupement et le coefficient du Rich Club. Elles ont toutes présenté des distributions et des médianes quasi identiques entre les différents types MBTI, qu'il s'agisse du réseau complet ou du réseau filtré. Les seuls écarts notables concernaient la distinction entre noeuds connus et noeuds "Unknown", ces derniers occupant une position structurellement plus périphérique.

L'analyse d'hétérophilie a permis de dégager un second éclairage sur la question. La distribution des proportions MBTI par film a révélé une structure multimodale fortement influencée par la taille réduite des castings matchés, plutôt qu'une tendance affirmée vers l'homogénéité ou la mixité des profils. Le score d'hétérophilie global, avec une moyenne de 0.747, a néanmoins mis en évidence une tendance statistique des castings vers une composition mixte des profils de personnalité, tendance qui s'est avérée être en grande partie un artefact de l'effectif d'acteurs matchés par film plutôt qu'une logique volontaire de diversification lors du processus de casting. La recherche de communautés par K-Means a permis d'identifier cinq profils de casting récurrents, mais ceux-ci se sont révélés peu différenciés, leurs centroïdes restant proches du centre de l'espace standardisé.

En définitive, les résultats obtenus dans ce projet ne permettent pas de conclure à l'existence d'un lien entre le type de personnalité MBTI des acteurs et la structure de leurs collaborations cinématographiques. Cette conclusion obtenue par la convergence de multiples méthodes d'analyse indépendantes, invite à considérer que la composition des castings cinématographiques répond davantage à des logiques commerciales, artistiques et relationnelles qu'à des affinités de personnalité.

Références

- [1] S.M. AYYOUBZADEH et al. « Can Invisible Psychological Traits Organize Visible Network Structure? A Complex Network Analysis of Myers–Briggs Type Indicator-Based Interaction Patterns in Anonymous Social Networks ». In : *Cornell University* (2025). DOI : <https://doi.org/10.48550/arXiv.2503.19704>.
- [2] Murray R. BARRICK et al. « Relating Member Ability and Personality to Work-Team Processes and Team Effectiveness ». In : *Journal of Applied Psychology* (1998). DOI : <https://doi.org/0021-9010/9843-00>.
- [3] Luiz Fernando CAPRETZ et Faheem AHMED. « Making Sense of Software Development and Personality Types ». In : *IT Professional* 12 (2010). DOI : <https://doi.org/10.1109/MITP.2010.33>.
- [4] V. GAROUSI et A. TARHAN. « Investigating the Impact of Team Formation by Introversion/Extraversion in Software Projects ». In : *Balkan Journal of Electrical and Computer Engineering* (2018). DOI : <https://doi.org/10.17694/bajece.419645>.
- [5] A.R. GILAL et al. « A rule-based model for software development team composition : Team leader role with personality types and gender classification ». In : *Information and Software Technology* (2016). DOI : <http://dx.doi.org/10.1016/j.infsof.2016.02.007>.
- [6] A.R. GILAL et al. « Software development team composition : Personality types of programmer and complex network ». In : *Computer Science, Psychology* (2017).
- [7] P.F. LAZARSFELD et R.K. MERTON. *Freedom and Control in Modern Society*. Friendship as a Social Process : A Substantive and Methodological Analysis, pp.18-66. Van Nostrand Company, 1954.
- [8] Miller MCPHERSON, Lynn SMITH-LOVIN et James M COOK. « BIRDS OF A FEATHER : Homophily in Social Networks ». In : *Annual Review of Sociology* (2001). DOI : <https://doi.org/10.1146/annurev.soc.27.1.415>.
- [9] Andrew THATCHER et Anthony De La COUR. « Small group decision-making in face-to-face and computer-mediated environments : the role of personality ». In : *Behaviour & Information Technology* 22 (2003). DOI : <https://doi.org/10.1080/0144929031000117071>.
- [10] Daniel VARONA et Luiz Fernando CAPRETZ. « Assessing a candidate's natural disposition for a software development role using MBTI ». In : *PPIG 2020* (2020).
- [11] M. YILMAZ et al. « An examination of personality traits and how they impact on software development teams ». In : *Information and Software Technology* (2017). DOI : <http://dx.doi.org/10.1016/j.infsof.2017.01.005>.